1. Анализ Big Data-сценариев и выбор технологий

Методические рекомендации

Цель лабораторной работы

Научиться:

1. Анализировать реальные данные по критериям 5V (Volume, Velocity, Variety, Veracity, Value)
2. Оценивать пригодность данных для решения бизнес-задач
3. Выбирать технологии под конкретные требования
4. Рассчитывать потенциальную бизнес-ценность решения

Система оценивания (максимум 10 баллов)

Критерий	Баллы	Описание
Анализ Volume	1.5	Корректная оценка объема, учет сжатия, прогноз роста
Анализ Velocity	1.5	Расчет скорости поступления, оценка задержки
Анализ Variety	1.5	Оценка структуры данных, обработка неструктурированных частей
Анализ Veracity	1.5	Выявление аномалий, оценка качества данных
Анализ Value	1.5	Расчет ROI, обоснование бизнес-ценности
Выбор технологий	1.5	Обоснованный выбор под конкретные 5V
Отчетность	1.0	Четкость изложения, визуализация, структура

Задание

Инструкция

1. Выберите **один** датасет из таблицы ниже (ваш вариант определяется по последней цифре вашей зачетной книжки)
2. Выберите **один** бизнес-сценарий из предложенных
3. Проведите анализ данных по критериям 5V
4. Подготовьте рекомендации по выбору технологий
5. Рассчитайте потенциальную бизнес-ценность решения
6. Оформите результаты в Jupyter Notebook

Варианты датасетов

Последняя цифра зачетки	Датасет	Описание	Особенности
0	NYC Taxi Trips	Данные о таксомоторных поездках в Нью-Йорке	Большой объем, временные метки, геоданные
1	Amazon Reviews	Отзывы о товарах на Amazon	Текстовые данные, рейтинг, метаданные
2	Credit Card Transactions	Транзакции кредитных карт	Высокая скорость поступления, необходимость real-time обработки
3	Twitter Streaming Data	Поток данных из Twitter	Высокая скорость, неструктурированные данные
4	IoT Sensor Data	Данные с датчиков IoT	Высокая скорость, шум в данных
5	E-commerce Clickstream	Данные о кликах в интернет-магазине	Высокая скорость, разнообразие событий
6	Hospital Readmissions	Медицинские данные о повторных госпитализациях	Чувствительные данные, сложная структура
7	Energy Consumption	Данные об энергопотреблении	Временные ряды, сезонность
8	MovieLens	Данные о рейтингах фильмов	Разреженные данные, рекомендательная система
9	Airline Delays	Данные о задержках рейсов	Большие объемы, временные метки, внешние факторы

Бизнес-сценарии (выберите один)

1. **Рекомендательная система**
   - Цель: увеличить средний чек на 15%
   - Ограничения: задержка инференса < 100 мс
   - Особенности: необходимо учитывать временные паттерны поведения
2. **Fraud Detection**
   - Цель: снизить мошеннические транзакции на 30%
   - Ограничения: задержка обработки < 50 мс
   - Особенности: необходимость обработки late-arriving данных
3. **Прогнозирование спроса**
   - Цель: сократить избыток запасов на 25%
   - Ограничения: ежедневные прогнозы должны завершаться до 6:00 утра
   - Особенности: необходимо учитывать внешние факторы (погода, праздники)
4. **Анализ логов и мониторинг**
   - Цель: снизить MTTR (Mean Time To Repair) на 40%
   - Ограничения: обнаружение аномалий в реальном времени
   - Особенности: необходимость обработки неструктурированных логов
5. **IoT-телеметрия (раннее предупреждение)**
   - Цель: предотвратить перегрев и отказ оборудования, сократив незапланированные простои
   - Ограничения: указать требуемый lead time и допустимую частоту ложных срабатываний, обосновав их ценой ошибки (логика newsvendor)
   - Особенности: квантильный прогноз (верхний квантиль, а не точечный), сезонность и дрейф, цена ложной тревоги, инженерия алертов (persistence k = 3, cooldown)
6. **Мультимодальный e-commerce (картинка + таблица)**
   - Цель: повысить точность категоризации товаров и качество рекомендаций

- Ограничения: latency инференса
- Особенности: join эмбеддингов с табличными признаками, риск утечки при обучении probe-моделей

Подробное задание

Часть 1: Анализ Volume (объем данных)

1. Загрузите датасет и определите его текущий объем в несжатом виде (в МБ или ГБ)
2. Оцените, какой объем займет этот датасет при использовании:
   - CSV формата
   - Parquet формата (оцените степень сжатия)
   - Avro формата (оцените степень сжатия)
3. Рассчитайте, как будет расти объем данных:
   - Ежедневный прирост (на основе временных меток)
   - Годовой объем при текущей скорости генерации
   - Через сколько месяцев объем превысит 1 ТБ
4. Определите, какие данные можно архивировать (а какие нужно хранить "горячими")
5. Рассчитайте стоимость хранения в облаке (Yandex Object Storage) для 1 года данных в Parquet формате

Требования к отчету:

- Таблица сравнения форматов хранения с цифрами
- График роста объема данных
- Расчет стоимости хранения
- Вывод о том, при каком объеме потребуется переход от Pandas к Spark

Часть 2: Анализ Velocity (скорость поступления данных)

1. Определите частоту поступления данных:
   - Среднее количество записей в секунду
   - Пиковая нагрузка (максимум за 5-минутный интервал)
   - Коэффициент вариации (стабильность потока)
2. Рассчитайте, какая задержка будет при обработке через:
   - Пакетную обработку (batch) раз в час
   - Микробатч обработку каждые 5 минут
   - True streaming обработку
3. Оцените, сколько данных будет "потеряно" при сбое системы на 30 минут
4. Определите, какая задержка допустима для вашего бизнес-сценария (обоснуйте цифрой)
5. Рассчитайте, сколько ресурсов потребуется для обработки пиковой нагрузки с задержкой < X мс (где X - ваше ограничение из бизнес-сценария)

Требования к отчету:

- График распределения событий во времени
- Расчет требуемых ресурсов для обработки пиковой нагрузки
- Обоснование выбора между batch/micro-batch/streaming
- Вывод о том, какие технологии подходят под ваши требования к задержке

Часть 3: Анализ Variety (разнообразие данных)

1. Проведите анализ структуры данных:
   - Количество и типы полей (числовые, категориальные, текстовые)
   - Доля неструктурированных данных (если есть)
   - Сложность вложенных структур (JSON внутри данных)
2. Выявите проблемы с разнообразием:
   - Несогласованные форматы дат
   - Разные форматы чисел (с запятыми/точками)
   - Пропуски в разных частях данных
3. Оцените, сколько усилий потребуется для обработки неструктурированных данных:
   - Для текстовых данных: необходимость NLP обработки
   - Для геоданных: необходимость геопространственного анализа
4. Определите, какие данные можно преобразовать в структурированный вид, а какие нужно обрабатывать как есть
5. Предложите схему хранения, которая будет учитывать разнообразие данных

Требования к отчету:

- Статистика по типам данных
- Примеры проблем с разнообразием (конкретные записи)
- Предложение по обработке неструктурированных данных
- Вывод о том, какие технологии лучше всего справляются с variety в ваших данных

Часть 4: Анализ Veracity (достоверность данных)

1. Проведите анализ качества данных:
   - Доля пропусков по ключевым полям
   - Наличие аномальных значений (например, отрицательные суммы транзакций)
   - Проверка на дубликаты
2. Оцените влияние проблем с качеством данных на ваш бизнес-сценарий:
   - Как ошибка в 1% данных повлияет на результат?
   - Какие данные критичны к качеству, а какие могут содержать шум?
3. Предложите стратегию обработки данных с низкой достоверностью:
   - Какие данные можно игнорировать?

- Какие нужно очищать?
- Какие требуют ручной проверки?

4. Реализуйте простую проверку данных с использованием Great Expectations:

```
import great_expectations as ge

# Создайте проверку для одного из критичных полей
# Например, для суммы транзакции: должна быть положительной
expectation = {
    "expectation_type": "expect_column_values_to_be_between",
    "kwargs": {"column": "amount", "min_value": 0, "max_value": None}
}
```

5. Оцените, как часто нужно проводить проверку качества данных

Требования к отчету:

- Таблица с метриками качества данных
- Примеры конкретных ошибок в данных
- Реализованная проверка через Great Expectations
- Вывод о том, как проблемы с veracity повлияют на выбор технологии

Часть 5: Анализ Value (ценность данных)

1. Оцените текущую ценность данных:
   - Какие метрики бизнеса можно улучшить с помощью этих данных?
   - Какой потенциальный доход можно получить?
2. Рассчитайте ROI проекта:
   - Затраты на инфраструктуру (обработка, хранение, разработка)
   - Потенциальная прибыль от реализации бизнес-сценария
   - Срок окупаемости проекта
3. Определите, какие данные приносят наибольшую ценность:
   - Проведите ABC-анализ (20% данных дают 80% ценности?)
   - Какие данные можно не обрабатывать без ущерба для бизнеса?
4. Предложите стратегию мониторинга ценности данных после запуска системы:
   - Какие метрики отслеживать?
   - Как часто пересчитывать ROI?
5. Оцените, как изменится ценность данных через 1 год (учитывая конкуренцию, изменения в бизнесе)

Требования к отчету:

- Расчет ROI с цифрами
- График зависимости ценности от объема обработанных данных

- Предложение по приоритизации данных
- Вывод о том, оправданы ли затраты на обработку данных для вашего сценария

Часть 6: Выбор технологий и рекомендации

1. На основе анализа 5V предложите технологический стек:
   - Для хранения данных (S3, HDFS, Delta Lake)
   - Для обработки (Spark, Flink, Kafka Streams)
   - Для ML (MLflow, Feature Store)
   - Для оркестрации (Airflow, Prefect)
2. Обоснуйте выбор каждой технологии с точки зрения:
   - Как она решает проблемы, выявленные в анализе 5V
   - Какие у нее ограничения в вашем сценарии
   - Какие альтернативы вы рассматривали и почему от них отказались
3. Предложите архитектуру системы:
   - Схема обработки данных (можно нарисовать в Mermaid)
   - Оценка требуемых ресурсов
   - План миграции с текущего состояния
4. Определите критические точки риска в вашем решении и способы их минимизации
5. Составьте roadmap внедрения на 6 месяцев с четкими этапами и метриками успеха

Требования к отчету:

- Схема архитектуры системы
- Таблица сравнения технологий с обоснованием выбора
- План внедрения с этапами и сроками
- Вывод о том, как ваше решение учитывает все 5V и бизнес-требования

Требования к оформлению работы

1. **Репозиторий на GitHub/GitLab**:
   - Должен содержать Jupyter Notebook с анализом
   - Файлы с данными не должны быть в репозитории (только ссылки на источники)
   - Должен быть файл `README.md` с кратким описанием
2. **Jupyter Notebook должен**:
   - Иметь четкую структуру по разделам задания
   - Содержать комментарии к коду
   - Включать визуализацию (графики, диаграммы)
   - Завершаться краткими выводами по каждому разделу

- Быть воспроизводимым (должен запускаться с нуля)

3. **Пример структуры Notebook**:

```
# Лабораторная работа 1: Анализ Big Data-сценариев

## Введение
- Используемый датасет: [название]
- Бизнес-сценарий: [название]
- Основные цели анализа

## Часть 1: Анализ Volume
### 1.1. Текущий объем данных
[код, результаты, графики]
### 1.2. Сравнение форматов хранения
[код, таблица, выводы]
... и т.д.

## Заключение
- Краткие итоги по каждому из 5V
- Рекомендации по технологиям
- Оценка бизнес-ценности решения
```